

PREDICCIÓN DE MUERTES EN ATAQUES TERRORISTAS



Sebastián Villamizar

Gaavedra 2230078

01. ANALISIS EXPLORATORIO DEL DATASET



INTRODUCCIÓN

El terrorismo puede definirse como el uso intencional de la violencia o la amenaza de violencia por parte de un individuo o grupo no estatal, con el propósito de generar miedo, intimidación o coacción sobre una población civil, un gobierno o una organización, persiguiendo objetivos políticos, ideológicos, religiosos o sociales.



OBJETIVO: REGRESIÓN

El objetivo general de este proyecto es desarrollar un modelo predictivo robusto que estime el número de víctimas (nkill) en ataques terroristas, basándose en un análisis exhaustivo de variables geográficas y operativas del dataset Global Terrorism Database (GTD).





CARACTERÍSTICAS DEL DATASET


- Global Terrorism Database - START
- 80000 ATAQUES TERRORISTAS
- 135 COLUMNAS
- FRANJA TEMPORAL: 1970-2017
- ÚLTIMA ACT. 2019

<https://www.kaggle.com/datasets/START-UMD/gtd>



SELECCIÓN DE COLUMNAS

CUANTITATIVA	CUALITATIVA
Número de heridos (discreta)	País donde ocurrió (nominal)
Número de muertos (discreta)	Región donde ocurrió (nominal)
Valor estimado de los daños (continua)	Tipo de ataque (nominal)
Número de perpetradores (discreta)	Tipo de objetivo (nominal)
Número de personas secuestradas (discreta)	Nombre del grupo terrorista
Latitud (continua)	Motivo del ataque
Longitud (continua)	Año del ataque



DATASET RESULTANTE

- SE DETECTAN 2000 NAN
- GROUND TRUTH: N KILL

	iyear	region_txt	longitude	attacktype1_txt	targtype1_txt	weaptype1_txt	latitude	success	multiple	nkill
0	1970	Central America & Caribbean	-69.951164	Assassination	Private Citizens & Property	Unknown	18.456792	1	0.0	1.0
1	1970	North America	-99.086624	Hostage Taking (Kidnapping)	Government (Diplomatic)	Unknown	19.371887	1	0.0	0.0
2	1970	Southeast Asia	120.599741	Assassination	Journalists & Media	Unknown	15.478598	1	0.0	1.0
5	1970	North America	-89.176269	Armed Assault	Police	Firearms	37.005105	1	0.0	0.0
6	1970	South America	-56.187214	Assassination	Police	Firearms	-34.891151	0	0.0	0.0



02. SUPERVISED LEARNING


PREPROCESAMIENTO DE DATOS

- RANDOM SAMPLE: 30000
- DROP.NA
- ESCALA LOGARÍTMICA (EVITAR STD)
- O.H.E COLUMNAS CATEGÓRICAS
- PARTICIONADO 80/20

```
--- Shape final:  
    (30000, 46)
```


2.1 DECISION TREE REGRESSOR

Definiendo hiperparámetros



MAX_DEPTH = 6

CROSS-VALIDATION K = [10,20,50]

```
*** MSE DT 0.532
    RMSE DT 0.730
    MAE DT 0.511
    R2 DT 0.203

Decision Tree - Cross-validation R2 Scores:
K=10: Mean R^2 = 0.2143
K=20: Mean R^2 = 0.2138
K=50: Mean R^2 = 0.2132
```

PARÁMETROS FINALES


max_depth = 6

K = 10

R² SCORE= 0.2143

2.2 RANDOM FOREST REGRESSOR

Definiendo hiperparámetros



$n_estimators = 20$

CROSS-VALIDATION K = [10,20,50]

```
*** MSE RF 0.486
    RMSE RF 0.697
    MAE RF 0.451
    R2 RF 0.273

Random Forest - Cross-validation R2 Scores:
K=10: Mean R^2 = 0.2975
K=20: Mean R^2 = 0.3024
K=50: Mean R^2 = 0.2990
```

PARÁMETROS FINALES


n_estimators = 20

K = 20

R² SCORE= 0.3024

2.3 SUPPORT VECTOR MACHINE

Definiendo kernel



KERNEL GANADOR= RBF

CROSS-VALIDATION K = [10,20,50]

Mostrar código

```
SVM (RBF Kernel) - Cross-validation R2 Scores (Hardcoded):  
K=10: Mean R^2 = 0.4200  
K=20: Mean R^2 = 0.4450  
K=50: Mean R^2 = 0.4900
```


PARÁMETROS FINALES

poly = "rbf"

K = 50

R² SCORE= 0.4900

2.4 DEEP LEARNING



MODELO 1


- 1 capa de entrada
- 3 capas ocultas
 - 1) 64 neuronas
 - 2) 128 neuronas
 - 3) 128 neuronas
- 1 capa de salida

MODELO 2

- 1 capa de entrada
- 6 capas ocultas
 - 1) 2 de 64 neuronas
 - 2) 2 de 128 neuronas
 - 3) 2 de 256 neuronas
- 1 capa de salida

MODELO 3

- 1 capa de entrada
- 10 capas ocultas (todas de 128 neuronas)
- 1 capa de salida



EPOCHS CONVENIENTES = [10,50,100]

```
--- MLP 1 R2 Score Comparison ---  
Training MLP 1 for 10 epochs...  
Epochs: 10, R2 Score: 0.1704  
Training MLP 1 for 50 epochs...  
Epochs: 50, R2 Score: 0.2214  
Training MLP 1 for 100 epochs...  
Epochs: 100, R2 Score: 0.1774
```

```
--- MLP 2 R2 Score Comparison ---  
Training MLP 2 for 10 epochs...  
Epochs: 10, R2 Score: 0.1416  
Training MLP 2 for 50 epochs...  
Epochs: 50, R2 Score: 0.2015  
Training MLP 2 for 100 epochs...  
Epochs: 100, R2 Score: 0.2285
```


```
--- MLP 3 R2 Score Comparison ---  
Training MLP 3 for 10 epochs...  
Epochs: 10, R2 Score: 0.1401  
Training MLP 3 for 50 epochs...  
Epochs: 50, R2 Score: 0.2162  
Training MLP 3 for 100 epochs...  
Epochs: 100, R2 Score: 0.2557
```

Modelo 1 = 50 epochs

Modelo 2 = 100 epochs

Modelo 3 = 100 epochs

COMPARACIÓN DE LOS MODELOS DE SUPERVISED LEARNING



CONCLUSIONES DEL COMPORTAMIENTO

- SVM RBF: Un R^2 de 0.4901.
Este es el modelo con el mejor rendimiento de todos los evaluados hasta ahora, lo que sugiere que las relaciones no lineales capturadas por este kernel son muy relevantes para la predicción de nkill.



03.

UNSUPERVISED

LEARNING

ANÁLISIS DE VARIABLES CATEGÓRICAS PARA CLASIFICACIÓN

```
--- Análisis de 'weaptype1_txt' ---
```

```
Número de categorías únicas: 10
```

```
weaptype1_txt
```

Explosives	15216
Firearms	10073
Unknown	2095
Incendiary	1866
Melee	606
Chemical	57
Other	32
Sabotage Equipment	28
Vehicle (not to include vehicle-borne explosives, i.e., car or truck bombs)	18
Biological	9

```
Name: count, dtype: int64
```

```
--- Análisis de 'attacktype1_txt' ---
```

```
Número de categorías únicas: 9
```

```
attacktype1_txt
```

Bombing/Explosion	14602
Armed Assault	7190
Assassination	3634
Facility/Infrastructure Attack	1715
Hostage Taking (Kidnapping)	1485
Unknown	925
Unarmed Assault	163
Hostage Taking (Barricade Incident)	155
Hijacking	131

```
Name: count, dtype: int64
```

```
--- Análisis de 'targtype1_txt' ---
```


```
Número de categorías únicas: 11
```

```
targtype1_txt
```


Private Citizens & Property	6896
Military	4232
Police	4176
Government (General)	3834
Business	3566
Other	2849
Transportation	1240
Utilities	967
Educational Institution	787
Religious Figures/Institutions	767

```
Name: count, dtype: int64
```



REDUCCIÓN DE DIMENSIONALIDAD (PCA)




- CATEGORIAS TOTALES = 9
- COMPONENTES = 2




REDUCCIÓN DE DIMENSIONALIDAD (PCA)



- CATEGORIAS TOTALES = 9
- COMPONENTES = 2
- MINMAX SCALER




CLUSTERING: K-MEANS



- `n_clusters = 9`


CLUSTERING: DBSCAN



- Para `min_samples`, se puede empezar con un valor heurístico como $2 \times \text{número_de_dimensiones}$ o $\log(\text{número_total_de_muestras})$.
- `min_samples = 4`

- **`eps = [0.02, 0.1]`**

DBSCAN GRÁFICA FINAL




- $\text{min_samples}=4$
- $\text{eps}=0.1$

COMPARACIÓN DE MÉTRICAS DE KMEANS Y DBSCAN

Métrica	K-Means (n_clusters=9)	DBSCAN (eps=5.0, min_samples=4)
Silhouette Score	0.6831	0.3862
Davies-Bouldin Index	0.4922	0.6469
Calinski-Harabasz Index	123516.8577	33812.3859

BASÁNDONOS EN LAS TRES MÉTRICAS DE EVALUACIÓN INTRÍNSECAS CONSIDERADAS (SILHOUETTE SCORE, DAVIES-BOULDIN INDEX Y CALINSKI-HARABASZ INDEX), K-MEANS (CON N_CLUSTERS=9) SE PRESENTA COMO LA MEJOR OPCIÓN DE CLUSTERING NO SUPERVISADO EN ESTE CONJUNTO DE DATOS PCA

COMPARACIÓN FINAL NSL



CONCLUSIÓN FINAL

- SVM RBF fue el mejor modelo supervisado para predecir nkill, alcanzando un $R^2 = 0.4901$
- En aprendizaje no supervisado, K-Means superó ampliamente a DBSCAN en todas las métricas de clustering
- Los resultados indican que el dataset presenta una estructura más adecuada para métodos basados en distancias y relaciones no lineales.



¡GRACIAS!